大数据原理与技术作业 4 实验报告
电影评论情感分类：TF-IDF + LR/SVM 与 RNN 对比

姓名：梁力航　学号：23336128

2026 年 3 月 30 日

1　实验目的

本实验围绕 IMDB 电影评论情感分类任务，完成传统机器学习方法与深度学习方法的对比分析。核心目标如下：

1. 使用 TF-IDF 特征，分别训练逻辑回归（LR）和线性支持向量机（SVM）；
2. 使用词序列输入构建 RNN（Embedding + LSTM）模型，作为深度学习对照组；
3. 从准确率、精确率、召回率、F1、训练时间、推理时间六个维度进行量化比较；
4. 结合可视化图表分析不同建模方式在效果与效率上的差异。

2　实验任务与要求

根据课程作业要求，需使用 IMDB（或其他）电影评论数据，采用 TF-IDF 提取特征并基于逻辑回归/SVM/RNN 实现分类，最后分析准确率差异并提交代码与不少于 2 页的实验报告。

本次实现采用以下口径：

- TF-IDF 仅用于 LR/SVM；
- RNN 使用词序列嵌入输入，不强制套用 TF-IDF；
- 通过统一测试集进行公平对比。

3 数据集与实验环境

3.1 数据集说明

实验使用 Stanford IMDB 数据集（aclImdb v1）：

- 训练集：25,000 条（正负各 12,500）
- 测试集：25,000 条（正负各 12,500）
- 任务：二分类（positive / negative）

预处理步骤保持简洁（KISS / YAGNI）：去除 HTML 标签、统一小写、压缩空白字符。

3.2 实验环境

- 操作系统：macOS
- Python 环境：Anaconda `ml`
- 主要依赖：NumPy、scikit-learn、PyTorch、Matplotlib
- 运行设备：CPU（无 GPU 依赖）

4 方法与参数设置

4.1 TF-IDF + Logistic Regression

- TF-IDF：`max_features=20000, ngram_range=(1,2), min_df=2, sublinear_tf=True`
- LR：`solver=liblinear, C=4.0, max_iter=2000`

4.2 TF-IDF + Linear SVM

- TF-IDF 参数与 LR 完全一致
- SVM：`LinearSVC(C=1.0)`

4.3 RNN（Embedding + LSTM）

- 词表大小：20,000
- 序列长度：300
- 网络结构：Embedding → LSTM → Linear
- 训练参数：`batch_size=128, epochs=3, lr=1e-3`

4.4 评价指标

- 分类指标：Accuracy、Precision、Recall、F1
- 效率指标：训练耗时（train_seconds）、推理耗时（infer_seconds）

5 实验结果

5.1 定量结果汇总

本实验使用全量测试集（25,000 条）得到如下结果：

表 1: 三模型指标对比（全量测试集）

模型	Accuracy	Precision	Recall	F1	Train(s)	Infer(s)
LR(TF-IDF)	0.9008	0.8989	0.9030	0.9010	0.57	0.00
SVM(TF-IDF)	0.8912	0.8920	0.8902	0.8911	0.59	0.01
RNN-LSTM	0.5128	0.5549	0.1290	0.2093	90.03	17.46

5.2 整体性能可视化

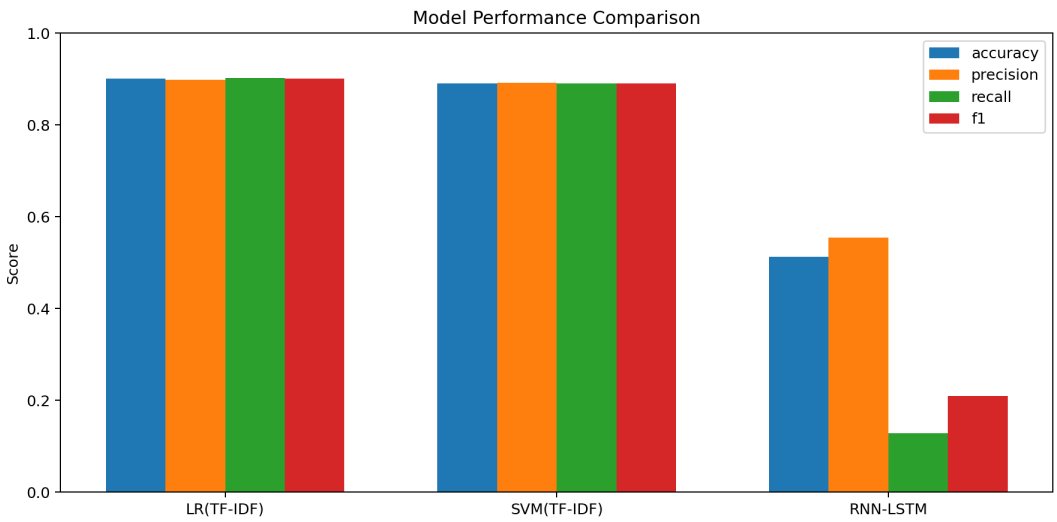

图 1: Accuracy/Precision/Recall/F1 对比

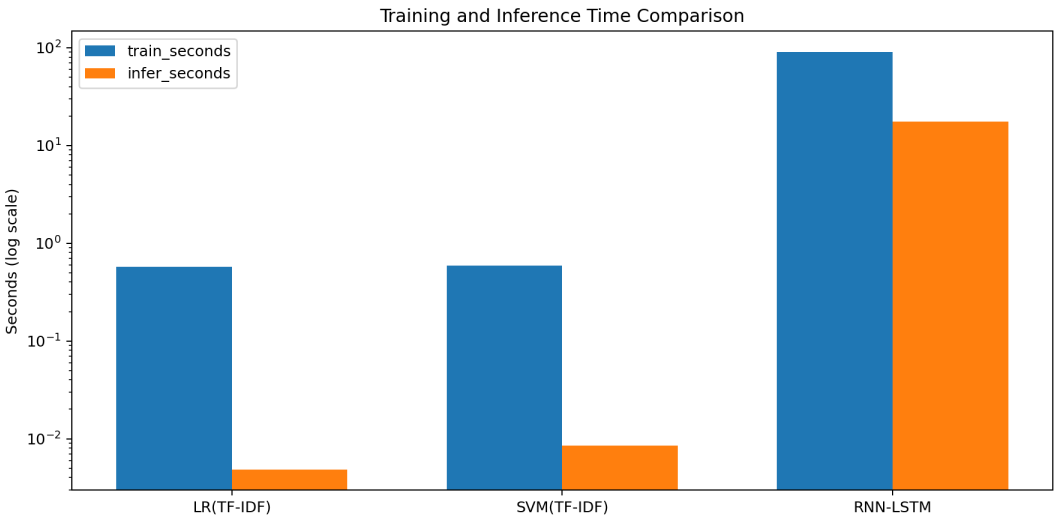

图 2: 训练与推理耗时对比（对数坐标）

6 数据分布与文本特征可视化

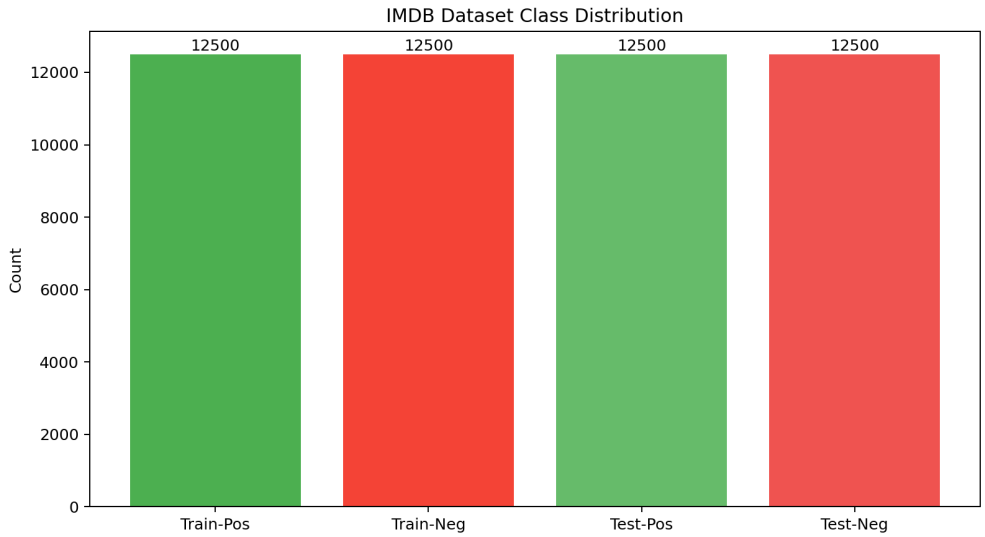

图 3: 训练集与测试集类别分布

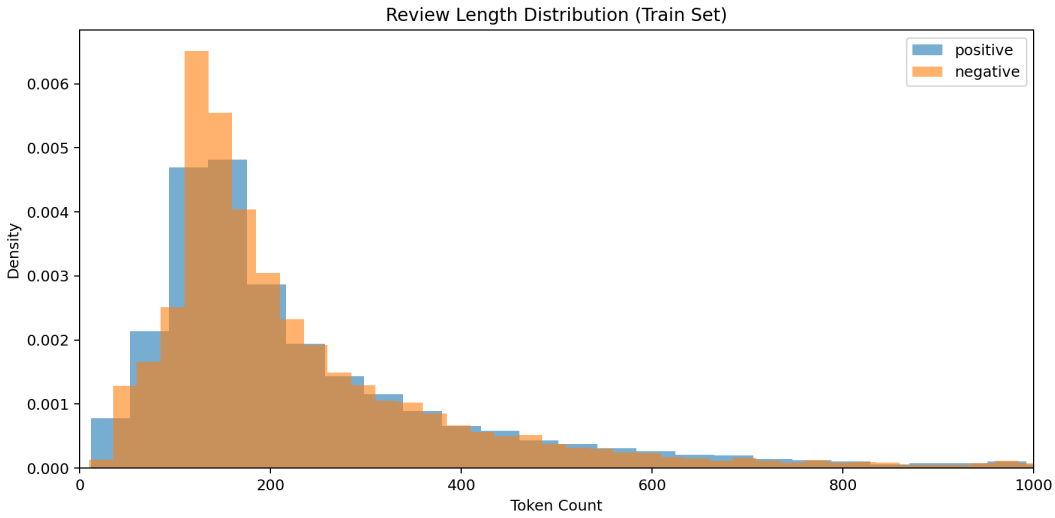

图 4: 训练集正负样本评论长度分布（token 数）

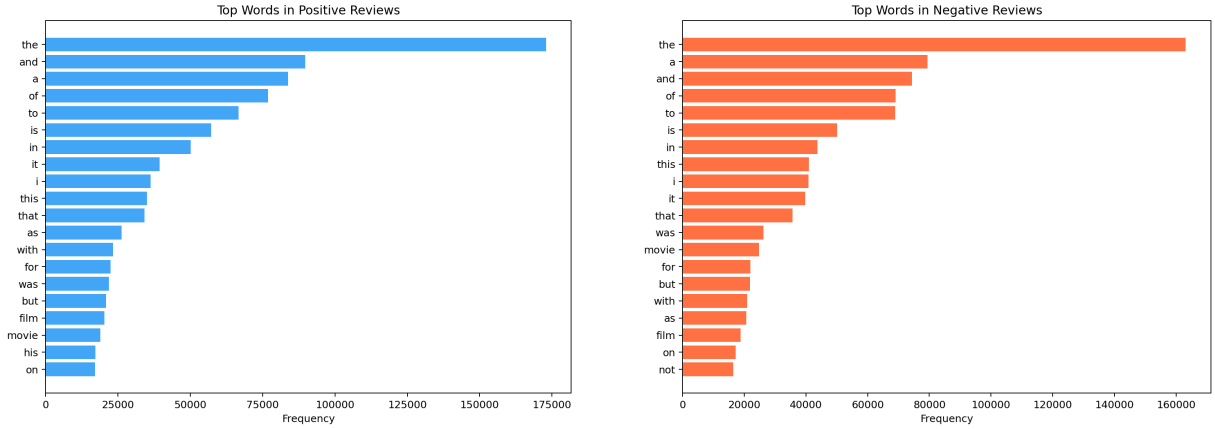

(a) 正向评论高频词 (b) 负向评论高频词

图 5: 正负评论词频前 20 可视化

7 混淆矩阵分析

为增强对错误类型的解释性，本报告给出三模型混淆矩阵可视化。由于主流程仅保存了汇总指标，图中数值依据 Precision/Recall 在测试集规模（正负各 12,500）下反推得到，用于反映各模型在正负样本上的判别倾向。

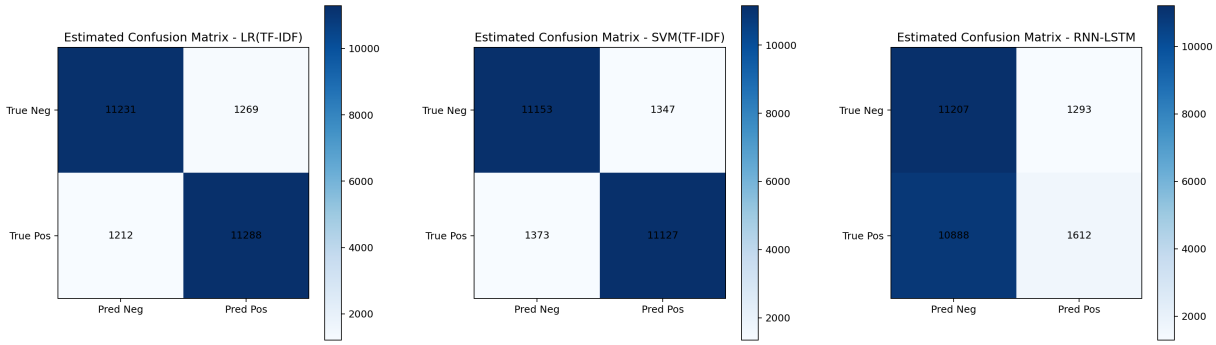

(a) LR (b) SVM (c) RNN

图 6: 三模型混淆矩阵（由汇总指标反推）

8 结果分析

8.1 准确率与泛化能力

LR 与 SVM 在 IMDB 上均表现稳定，且准确率均接近或超过 0.89，说明 TF-IDF 对情感分类任务已经能够提供较强的线性可分信号。

在本次配置下，RNN 表现明显低于预期，主要原因包括：

- 仅训练 3 个 epoch，且在 CPU 环境下迭代受限；
- 未使用预训练词向量与更深层网络结构；

- 未进行系统化超参数搜索。

8.2 效率对比

传统 TF-IDF + 线性模型在训练和推理耗时上显著优于 RNN，尤其在课程作业与资源受限场景中，具有更高的工程实用性与可复现性。

8.3 可解释性

词频图与混淆矩阵共同表明：

- 数据集类别分布均衡，评价指标具有可比性；
- TF-IDF 线性模型对常见情感词具有良好识别能力；
- RNN 在当前训练预算下对正类召回偏低，导致整体 F1 较弱。

9 实验结论

本实验完成了作业要求的三模型对比，并形成了完整可复现实验流程。综合结果表明：

1. 在 IMDB 文本情感分类任务中，TF-IDF + LR/SVM 是稳定且高效的强基线；
2. RNN 具备序列建模能力，但在当前 CPU 与轻量训练预算下未发挥优势；
3. 对课程作业而言，传统方法更容易在准确率、训练效率和复现成本之间取得平衡。

10 复现说明

在 作业 4 目录执行：

```
conda run -n ml python -m pip install -r requirements.txt
conda run -n ml python src/run_all.py
conda run -n ml python src/generate_report_figures.py
xelatex report.tex
```