大数据原理与技术作业 5 实验报告
股票价格预测：ARIMA 与 LSTM 对比

姓名：梁力航　学号：23336128

2026-03-30

1　实验目的

本实验围绕单变量股票收盘价序列预测任务，使用同一份历史价格数据分别构建 ARIMA 与 LSTM 模型，并完成测试集评估与未来 7 个交易日预测。实验目标包括：

1. 完成从本地 CSV 读取、清洗、切分到训练、预测、评估的一体化流水线；
2. 在同一测试集上使用 MAE 与 RMSE 对 ARIMA 和 LSTM 的效果进行比较；
3. 生成图表与表格，支撑模型效果分析；
4. 产出可提交的代码、结果文件与 PDF 报告。

2　数据集与实验环境

2.1　数据集说明

实验数据为 Apple 股票历史价格公开 CSV，经清洗后保留：

- `date`：交易日期
- `close`：收盘价

本次实验仅使用收盘价单变量序列建模，避免引入题目未要求的复杂特征工程，符合 KISS / YAGNI 原则。

2.2　实验环境

- 操作系统：macOS
- Python 环境：Anaconda `ml`

- 主要依赖：NumPy、Pandas、Matplotlib、statsmodels、scikit-learn、PyTorch
- 运行设备：CPU

3 方法设计

3.1 数据预处理

预处理流程如下：

1. 统一列名并解析日期；
2. 按时间升序排序并去重；
3. 按时间顺序切分训练集与测试集；
4. 针对 LSTM 构造固定窗口长度的监督学习样本。

3.2 ARIMA

ARIMA 部分先对训练序列执行平稳性检测，根据 ADF 结果推断差分阶数 d，再在有限参数范围内搜索 (p, q)，以 AIC 最小作为模型选择依据。测试集评估阶段采用滚动预测策略：每次仅预测下一交易日，并在获得该日真实值后将其并入历史序列，再继续拟合下一步。这种做法更贴近时间序列真实使用场景，也能避免一次性长跨度外推导致的预测塌缩。最后在全量序列上重新拟合模型，输出未来 7 天预测。

3.3 LSTM

LSTM 部分先对训练集价格做 Min-Max 缩放，再用长度为 `window_size` 的历史窗口预测下一时刻价格。网络结构采用单层 LSTM 加线性输出层，训练完成后在测试集上逐点预测，并通过递推方式生成未来 7 天价格预测。

4 实验结果

4.1 误差指标

表 1: ARIMA 与 LSTM 测试集指标对比

模型	MAE	RMSE	Train(s)	Infer(s)
ARIMA(0, 1, 2)	0.8137	1.2547	0.01	0.72
LSTM	2.1156	2.5984	1.38	0.00

4.2 未来 7 天预测结果

表 2: 未来 7 天预测结果

日期	ARIMA	LSTM
2017-02-17	135.3318	132.8280
2017-02-20	135.3354	132.8454
2017-02-21	135.3354	132.7145
2017-02-22	135.3354	132.5083
2017-02-23	135.3354	132.2623
2017-02-24	135.3354	131.9938
2017-02-27	135.3354	131.7144

5 可视化结果

图 1: 原始收盘价时间序列

图 2: 训练集与测试集切分

图 3: ARIMA 测试集预测对比

图 4: LSTM 测试集预测对比

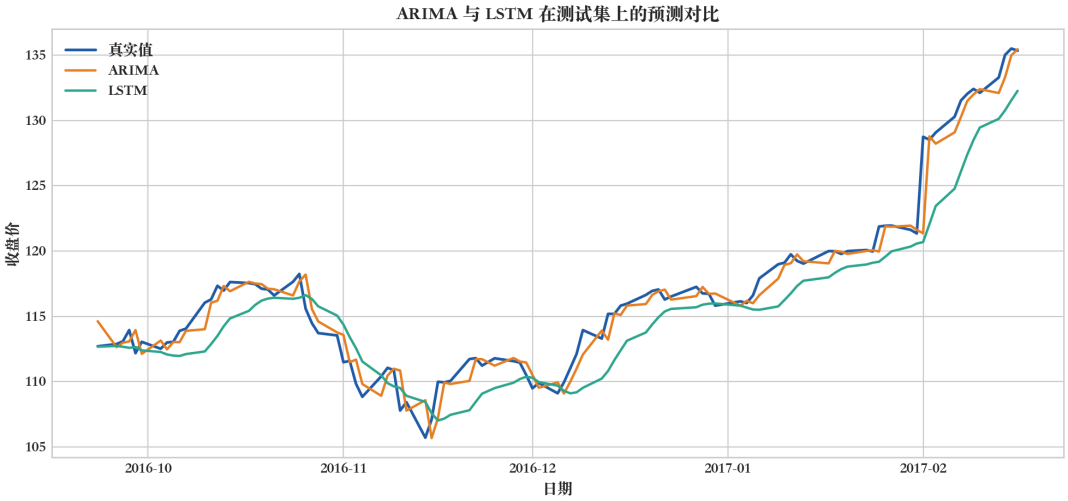

图 5: 两模型测试集预测综合对比

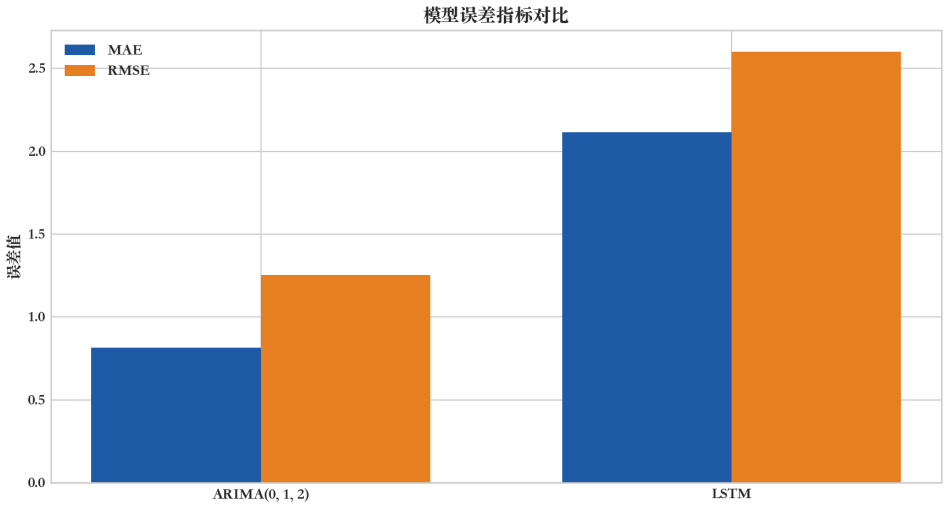

图 6: MAE 与 RMSE 指标对比

图 7: 未来 7 天价格预测

6 结果分析

从误差指标可以直接看出，当前实验中 ARIMA 的表现明显优于 LSTM。具体而言，ARIMA(0,1,2) 在测试集上的 MAE 为 0.8137、RMSE 为 1.2547，而 LSTM 的 MAE 为 2.1156、RMSE 为 2.5984。两项指标均显示 ARIMA 的预测误差约为 LSTM 的一半左右，说明在本数据集和当前实验设置下，ARIMA 对收盘价短期波动的刻画更加准确。

结合测试集对比图也可以发现，采用滚动预测后，ARIMA 能够更紧密地跟随真实价格走势，尤其在局部上升、回落和平台阶段都保持了较好的同步性。相比之下，LSTM 的预测曲线虽然总体趋势正确，但存在更明显的滞后和平滑现象，对短期突变的响应不如 ARIMA 灵敏。

这种结果具有明确的工程合理性。当前任务是单变量、短期、低维的时间序列预测，样本规模也较小，这正是传统统计模型更容易发挥优势的场景。ARIMA 结构简单、参数可解释、训练速度快，在有限样本下仍能保持稳定性能。LSTM 作为深度学习模型，通常更依赖更大的数据规模、更长的训练时间以及更细致的超参数搜索；在本次仅使用 CPU、轻量网络和有限训练轮数的设置下，其优势尚未充分体现。

因此，就本次课程作业的目标而言，ARIMA 不仅是一个可运行的基线模型，而且是当前实验条件下更稳健、更准确、也更容易解释的方案；LSTM 则作为对照模型，展示了深度学习方法在时间序列建模中的另一条技术路线。

7 实验结论

本实验完成了课程作业要求的全部核心内容：股票历史 CSV 清洗、ARIMA 与 LSTM 两类模型实现、测试集误差对比、未来 7 天预测、图表输出以及 PDF 报告生成。综合实验结果可知，在当前数据规模与实验预算下，采用滚动预测的 ARIMA 在精度上明显优于 LSTM，并表现出更强的稳定性与可解释性，因此可以作为本次股票价格预测任务中更合适的主模型。LSTM 能够完整复现深度学习预测流程，但若要进一步超过 ARIMA，仍需要更多数据、更长训练时间以及更充分的参数调优。

8 复现说明

在 作业 5 目录执行：

```
conda run -n ml python -m pip install -r requirements.txt
conda run -n ml python -m unittest discover -s tests -v
conda run -n ml python src/run_all.py
xelatex report.tex
xelatex report.tex
```