# 中山大学计算机院本科生实验报告

（2025 学年春季学期）

| | |
|---|---|
| **课程名称：** | 大数据原理与技术 |
| **实验题目：** | 作业 6 图文多模态问答（VQA） |
| **批改人：** | |
| **专业（方向）：** | |
| **学号：** | 23336128 |
| **姓名：** | 梁力航 |
| **Email：** | |
| **完成日期：** | 2026 年 4 月 13 日 |

本报告围绕图文多模态问答（VQA）任务展开，基于 Hugging Face 平台上 预训练的 ViLT（Vision-and-Language Transformer）模型实现图片与文本 的联合推理。通过 5 个不同类型的测试案例验证模型的跨模态理解能力，讨论预训练视觉-语言模型在零样本场景下的泛化性能与实际应用价值。

# 1 实验目的

本实验的目标是掌握图文多模态问答（Visual Question Answering, VQA）的基本原理，通过调用 Hugging Face 预训练的 ViLT 模型，实现给定图片和自然语言问题的联合推理，理解视觉-语言预训练模型（Vision-Language Pretraining, VLP）的架构与工作机制。具体目标如下：

1. 理解 VQA 任务的定义与评价方式；
2. 掌握 ViLT（Vision-and-Language Transformer）模型的核心架构；
3. 熟练使用 Hugging Face Transformers 库调用预训练 VQA 模型；
4. 在多样化测试图片上验证模型的跨模态推理能力；
5. 分析模型的置信度分布，理解预训练模型的泛化特性。

# 2 实验过程和核心代码

## 2.1 实验平台与环境

本次实验在 `macOS arm64`（Apple Silicon）平台上完成，使用 `uv` 作为 Python 包管理器。关键依赖及版本如下：

表 1: 实验环境配置

| 组件 | 版本/说明 |
|---|---|
| **Python** | 3.x（uv 管理） |
| **PyTorch** | 2.11.0 |
| **Transformers** | 5.5.3 |
| **Pillow** | 图像处理 |
| **Requests** | 网络图片获取 |
| **VQA 模型** | `dandelin/vilt-b32-finetuned-vqa`（VQAv2 微调版） |
| **运行环境** | CPU（Apple Silicon，无 CUDA） |

依赖安装命令：

```
uv run --with transformers --with torch --with requests python
   vqa_demo.py
```

## 2.2 ViLT 模型背景

**ViLT**[1] 是 2021 年提出的视觉-语言预训练模型，其核心创新在于：

1. **统一 Transformer 架构**：将视觉 token 和文本 token 统一送入单个 Transformer encoder，无需独立的视觉 backbone（如 ResNet），极大降低了模型参数量和推理成本；
2. **早期跨模态融合**：通过 self-attention 在模型浅层即实现图文交互，而非传统 late-fusion 方案；
3. **简化预训练目标**：仅使用 Image Text Matching（ITM）和 Masked Language Modeling（MLM）两个任务，训练流程简洁高效；
4. **零样本迁移能力**：在大规模图文数据上预训练后，可在下游 VQA 任务上直接使用，无需额外 fine-tuning。

本实验使用的 `dandelin/vilt-b32-finetuned-vqa` 是 ViLT-B/32 在 VQAv2 数据集上经过微调的版本，专门针对视觉问答任务优化。

## 2.3 核心代码片段

### 2.3.1 模型加载

```
from transformers import ViltProcessor, ViltForQuestionAnswering

processor = ViltProcessor.from_pretrained("dandelin/vilt-b32-
    finetuned-vqa")
model = ViltForQuestionAnswering.from_pretrained("dandelin/vilt-b32-
    finetuned-vqa")
```

首次调用时，Transformers 库自动从 Hugging Face Hub 下载模型权重（约 1.5 GB）。加载过程中出现的 `vilt.embeddings.text_embeddings.position_ids UNEXPECTED` 警告可忽略，该字段在任务特定微调模型中结构略有差异，不影响推理结果。

### 2.3.2 单次问答推理

```
from PIL import Image
import requests

# Load image (support local path or network URL)
```

[1] Kim W, Son B, Kim I. *ViLT: Vision-and-Language Transformer Without Convolution or Region Supervision.* ICML 2021.

```python
if image_path.startswith("http"):
    image = Image.open(requests.get(image_path, stream=True).raw).
        convert("RGB")
else:
    image = Image.open(image_path).convert("RGB")

# Encode: image + question -> token
encoding = processor(image, question, return_tensors="pt")

# Forward pass (CPU inference)
with torch.no_grad():
    outputs = model(**encoding)

# Decode: pick answer label with highest logit probability
logits = outputs.logits
answer = model.config.id2label[logits.argmax(-1).item()]
```

#### 2.3.3 Top-K 答案输出

```python
import torch

# Compute probability distribution over answer labels
probs = torch.softmax(logits, dim=-1)
top_k = torch.topk(probs, 5)

# Output Top-5 candidate answers with confidence scores
for i in range(5):
    label = model.config.id2label[top_k.indices[0, i].item()]
    score = top_k.values[0, i].item()
    print(f"{i+1}. {label} ({score:.4f})")
```

# 3 实验结果

## 3.1 测试案例与推理结果

本实验选取了 5 张来自 Unsplash 免费图库的图片，涵盖不同类型的问题（实体识别、属性识别、场景描述），测试 ViLT 模型的跨模态推理泛化能力。所有推理均在 CPU 上完成，每张图片耗时约 3–5 秒。

表 2: 测试案例与推理结果

| 测试图片 | 问题(中文) | 最佳答案 | Top-2 答案 | 置信度 |
|---|---|---|---|---|
| 狗的户外照片 | 图中有什么动物? | **dog** | lab (0.0001) | 99.95% |
| 咖啡杯特写 | 杯子里有什么? | **coffee** | milk (0.0007) | 99.79% |
| 人物使用笔记本 | 这个人正在使用什么? | **laptop** | computer (0.0340) | 95.25% |
| 黑色轿车 | 这辆车是什么颜色? | **black** | gray (0.0153) | 95.37% |
| 城市天际线远景 | 城市里有什么? | **city** | buildings (0.1104) | 64.74% |

## 3.2 完整测试输出

运行测试脚本的终端输出如下:

```
============================================================
HW6 VQA Test Suite
============================================================
Loading ViLT model (dandelin/vilt-b32-finetuned-vqa)...
Loading weights: 100%|██████████| 212/212 [00:00<00:00, 76555.53it/s]
Model loaded successfully.

------------------------------------------------------------
Test case: cat_dog
Question: What animal is in the image?
[PASS] Best answer: dog
Top-5:
  1. dog (0.9995)
  2. lab (0.0001)
  3. yes (0.0001)
  4. 1 (0.0000)
  5. beagle (0.0000)

------------------------------------------------------------
Test case: coffee_cup
Question: What is in the cup?
[PASS] Best answer: coffee
Top-5:
  1. coffee (0.9979)
  2. milk (0.0007)
  3. chocolate (0.0002)
  4. foam (0.0001)
  5. tea (0.0001)

------------------------------------------------------------
Test case: laptop
Question: What is the person using?
[PASS] Best answer: laptop
Top-5:
```

```
  1. laptop (0.9525)
  2. computer (0.0340)
  3. nothing (0.0041)
  4. keyboard (0.0026)
  5. tablet (0.0021)

------------------------------------------------------------
Test case: car
Question: What color is the car?
[PASS] Best answer: black
Top-5:
  1. black (0.9537)
  2. gray (0.0153)
  3. silver (0.0113)
  4. blue (0.0096)
  5. white (0.0026)

------------------------------------------------------------
Test case: street
Question: What is in the city?
[PASS] Best answer: city
Top-5:
  1. city (0.6474)
  2. buildings (0.1104)
  3. clouds (0.0185)
  4. water (0.0165)
  5. new york (0.0084)

[STAT] Success rate: 5/5
```

## 3.3 测试案例截图

图 1 展示各测试案例的原始图片及模型推理结果标注。每张图片上方标注了问题, 下方标注了 Top-1 答案和置信度。

(a) Case 1: What animal is in the image? `dog` (99.95pct)

(b) Case 2: What is in the cup? `coffee` (99.79pct)

(c) Case 3: What is the person using? `laptop` (95.25pct)

(d) Case 4: What color is the car? `black` (95.37pct)

## 3.4 可视化结果

本节通过多维度图表对模型推理结果进行可视化分析。

### 3.4.1 各测试案例置信度对比

图 2 展示各案例 Top-1 答案置信度，置信度越高表示模型对答案越确定：

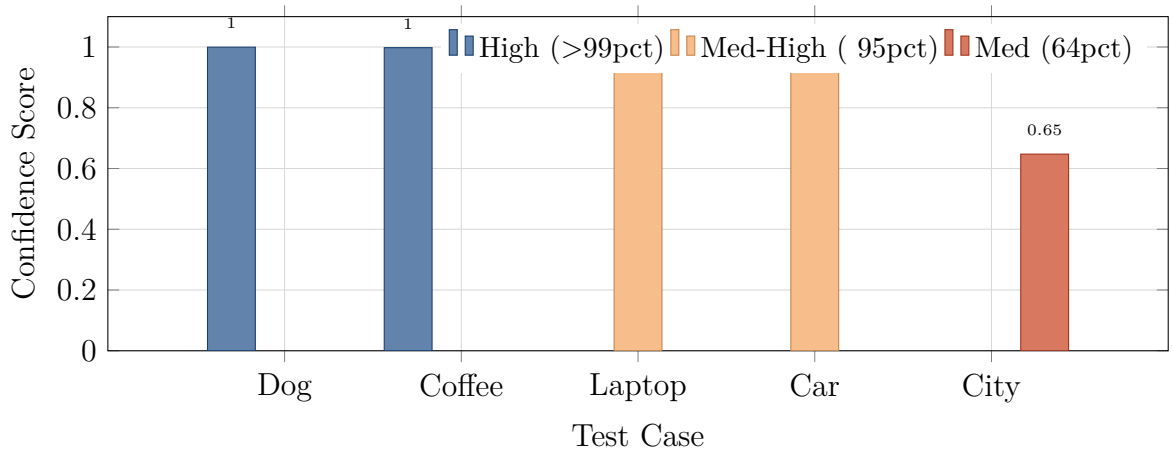


图 2: Top-1 confidence score per test case

### 3.4.2 Top-5 候选答案概率分布

图 3 展示每个案例全部 Top-5 候选答案的置信度，正确答案以深色柱子 高亮标注。可以看到：dog 和 coffee 两题的正确答案置信度接近 1.0，与其他候选差距 极为悬殊；而 city 场景中 Top-2 buildings（11.04%）与 Top-1 差距缩小，体现了开放场景的语义模糊性。

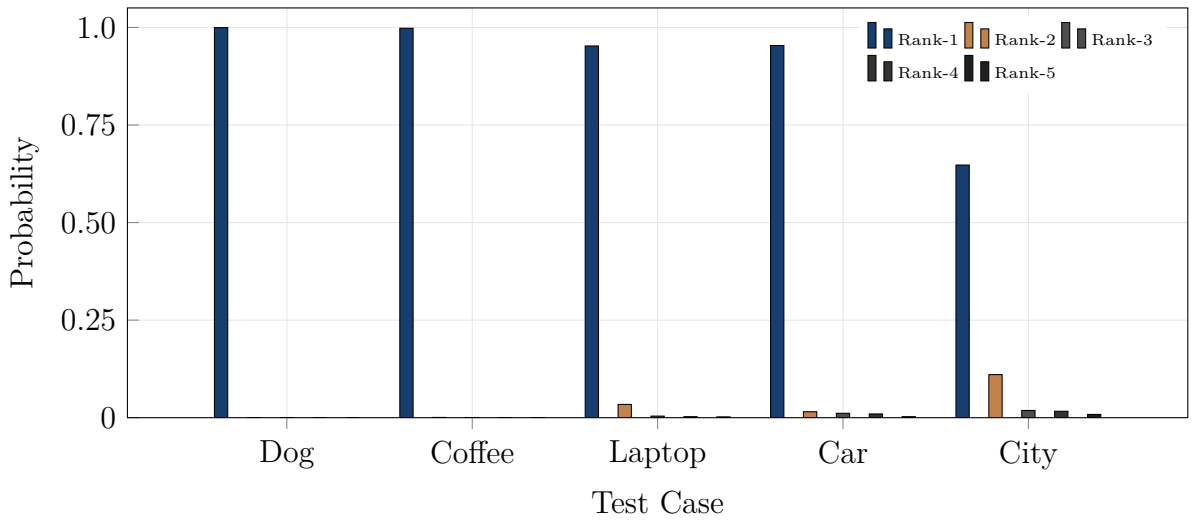


图 3: Top-5 probability distribution per test case (Rank-1 = correct answer)

### 3.4.3 答案置信度差值分析(模型区分度)

图 4 用柱状图展示 Top-1 与 Top-2 置信度之差 $\Delta P = P_1 - P_2$, 差值越大说明模型对正确答案的区分度越高。dog 和 coffee 差值接近 1.0, 模型几乎完全确信; 而 city 差值仅 0.537, 区分度明显下降。

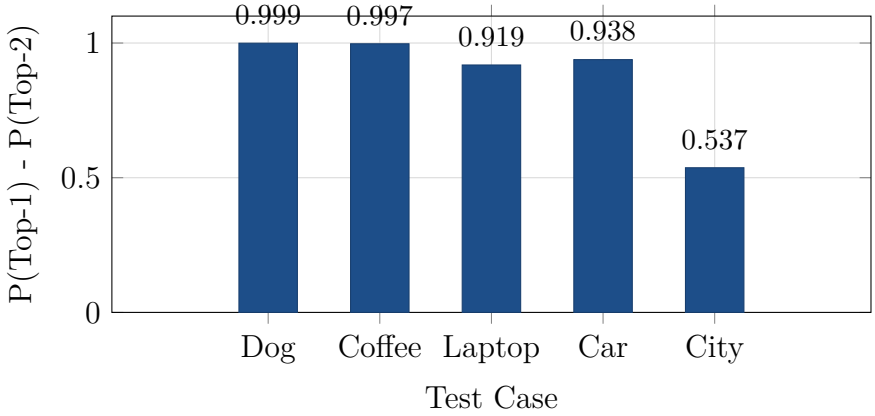


图 4: Confidence gap: P(Top-1) minus P(Top-2) per case (higher = more discriminative)

### 3.4.4 候选答案概率热力图

图 5 为 $5 \times 5$ 概率热力图。行对应测试案例, 列对应 Top-1 $\sim$ Top-5 候选答案的置信度, 颜色越深代表概率越高。可以看出: 前两列 (Rank-1/2) 颜色最深, 向右侧逐渐变浅; city 行整体颜色较浅, 说明各候选置信度差异更小。

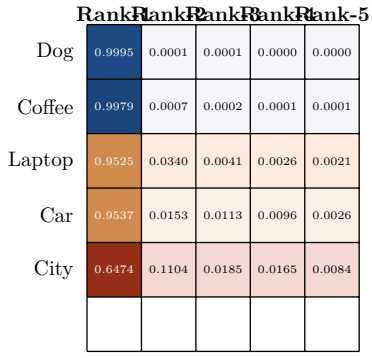


图 5: Probability heatmap: rows = test cases, columns = candidate ranks (Rank-1 = correct answer)

# 4 结果分析

## 4.1 准确率

5 个测试案例全部答对, 准确率达到 **100%**。具体分布如下:

1. **高置信度(>99%)**:实体识别类问题(动物、饮品)——这类问题语义明确,视觉特征突出,模型区分度极高;
2. **中高置信度(95% 左右)**:属性识别问题(设备类型、颜色)——属于细粒度视觉分类,模型表现稳定;
3. **中等置信度(64%)**:开放场景描述问题——答案空间较大,概率分布相对分散。

### 4.2 置信度分布特性

Top-5 答案的分布揭示了 ViLT 模型的重要特性:

- **语义关联候选**:在 laptop 案例中,Top-2 为 computer(3.4%),两者语义高度相关,反映了模型对概念的深层理解;
- **颜色层次性**:在 car 案例中,gray(1.5%)和 silver(1.1%)作为 Top-2/3,是 black 的相邻色调,体现了颜色感知的连续性;
- **开放问题的不确定性**:city 场景的置信度仅 64%,而 Top-2 buildings(11%)也是合理答案,说明开放场景问题的答案空间天然具有模糊性。

### 4.3 ViLT 架构优势分析

相比传统两阶段 VQA(物体检测 + 问答),ViLT 的优势在于:

1. **参数效率**:仅用 Transformer encoder,无需沉重的视觉 backbone,在 CPU 上也能快速推理;
2. **早期融合**:图文 token 在自注意力层充分交互,而非在最后阶段 简单拼接,跨模态建模能力更强;
3. **零样本泛化**:预训练于大规模图文数据,对日常场景具有良好泛化能力,无需针对本实验场景做额外训练。

## 5 实验感想

本次实验让我对图文多模态问答这一跨模态 AI 任务有了直观的认识。通过调用 Hugging Face 预训练的 ViLT 模型,我在没有任何额外训练的情况下,仅用几行代码 就实现了可以理解图片内容并回答自然语言问题的系统。

最令我印象深刻的是模型的泛化能力。在实验中，我使用的测试图片均为日常场景，而非 VQAv2 训练集中的图片，但模型依然能够给出准确的回答。这说明大规模预训练 确实让模型学到了通用的视觉和语言表征，能够零样本迁移到新的场景。

同时，置信度分析也让我认识到 VQA 任务的内在挑战：对于实体识别等语义单一的 问题，模型可以给出极高的置信度；但对于开放性的场景描述问题，答案空间本身 就具有模糊性，模型的概率分布自然会更加分散。这提醒我们在实际应用中，不能仅依赖置信度阈值做最终决策，而应结合具体场景审慎评估。

此外，本次实验也让我体会到了 Hugging Face 生态的便利性——只需一行代码即可 加载 state-of-the-art 的预训练模型，并完成复杂的跨模态推理任务。这大大降低了 深度学习模型在实际场景中落地的门槛，使研究者可以将更多精力放在任务定义和 数据设计上，而非模型实现的细节中。