大数据原理与技术作业 7 实验报告

混合推荐系统设计

课程名称：	大数据原理与技术
实验题目：	作业 7 混合推荐系统设计
学号：	23336128
姓名：	梁力航
完成日期：	2026 年 4 月 21 日
数据集：	MovieLens 100K
核心指标：	Recall@K、Diversity、Coverage、Novelty

本实验基于 MovieLens 100K 数据集实现四种推荐策略：用户协同过滤、物品协同过滤、基于内容的推荐和线性混合推荐。报告使用真实运行结果 `results.json` 与现有图表文件进行整理，重点比较召回率、多样性、覆盖率和新颖度，并通过 `K` 变化曲线、权重扫描和雷达图展示不同方法的行为差异。

说明：本报告仅使用已生成结果与图表，不改动算法实现。

摘要

本实验面向 MovieLens 100K 的推荐任务，构建并比较了用户协同过滤（User-CF）、物品协同过滤（Item-CF）、基于内容的推荐（Content-Based）和混合推荐（Hybrid）四种方法。真实结果表明，Hybrid 在 `Recall@10` 上达到 **0.0314**，在 `Recall@5/10/20/50` 的全部区间内均保持最优；User-CF 在多样性和覆盖率上更强，Item-CF 的新颖度最高。报告进一步结合权重扫描发现，`alpha=0.2` 时召回率最高，而当前提交版本采用的 `alpha=0.6` 更偏向平衡多指标的折中方案。全文以表格和图形为主，突出模型性能差异与权重变化趋势。

1 实验目的

本实验的目标是围绕 MovieLens 100K 推荐任务，完成四类推荐方法的实现、对比与分析，具体包括：

1. 理解用户协同过滤、物品协同过滤、基于内容推荐与混合推荐的基本思想；
2. 在统一数据划分下比较不同方法的召回率、多样性、覆盖率与新颖度；
3. 通过 `K` 变化曲线和权重扫描分析混合策略的行为边界；
4. 输出可直接提交的 TeX 与 PDF 报告，保证结果可复现、可核验。

2 数据与环境

2.1 数据集

实验数据采用 MovieLens 100K，包含 943 位用户、1682 部电影和 100000 条评分记录。评分矩阵按时间无关方式拆分为训练集 80000 条与测试集 20000 条，评估用户数为 920，推荐列表长度固定为 10。

表 1: 数据规模与实验设定

项目	取值
数据集	MovieLens 100K
用户数	943
电影数	1682
评分总数	100000
训练集 / 测试集	80000 / 20000
评估用户数	920
推荐列表长度	10

2.2 实验环境

实验在 macOS 环境下完成,算法运行依赖 `numpy`、`pandas`、`scikit-learn` 和 `matplotlib` 等常规 Python 库。当前报告严格基于已生成的 `results.json` 和 `figures/` 目录，不对推荐算法进行二次改写。

3 方法设计

3.1 用户协同过滤

User-CF 通过用户之间的余弦相似度寻找邻居，再对未评分物品进行加权聚合。该方法的优点是直观、可解释，缺点是对用户稀疏度较敏感。

3.2 物品协同过滤

Item-CF 先计算物品相似度，再根据用户历史行为推断候选物品得分。相较 User-CF，它更适合物品相对稳定、用户行为稀疏但物品可复用性较强的场景。

3.3 基于内容的推荐

Content-Based 使用电影类型特征构建物品表示，再与用户历史偏好进行匹配。该方法不依赖其他用户行为，但容易形成内容偏置，推荐结果的多样性通常较低。

3.4 混合推荐

Hybrid 采用线性加权融合策略，将协同过滤信号与内容信号进行组合：

$$S_{u,i} = \alpha \cdot S_{CF}(u,i) + (1-\alpha) \cdot S_{CB}(u,i)$$

其中 `alpha` 由实验结果决定。当前提交版本的最终混合结果对应 `alpha=0.6`，而权重扫描表明 `alpha=0.2` 在召回率上更激进，`alpha=1.0` 则更偏向纯协同过滤。

4 实验结果

4.1 总体指标

表 2 汇总了四种方法在核心指标上的真实结果。可以直接看到，Hybrid 在召回率上最优，User-CF 的多样性与覆盖率更高，Item-CF 的新颖度最高。

表 2: 四种推荐方法的总体指标

方法	Recall@10	Diversity	Coverage	Novelty
User-CF	0.0094	**0.7511**	**0.5297**	0.8594
Item-CF	0.0002	0.6929	0.2176	**0.9966**
Content-Based	0.0192	0.1360	0.4180	0.8790
Hybrid	**0.0314**	0.3404	0.4073	0.8121

4.2 Recall@K 对比

从 `K=5` 到 `K=50`，Hybrid 在所有区间都保持最优，说明混合策略不仅在单点指标上占优，也在更宽松的推荐列表长度下维持了稳定优势。

表 3: 不同 `K` 下的 Recall@K

方法	@5	@10	@20	@50
User-CF	0.0033	0.0094	0.0385	0.1686
Item-CF	0.0001	0.0002	0.0018	0.0038
Content-Based	0.0119	0.0192	0.0349	0.0787
Hybrid	**0.0153**	**0.0314**	**0.0680**	**0.1819**

4.3 权重扫描

权重分析结果表明，`alpha=0.2` 时 Recall@10 最高，达到 **0.0450**；随着 `alpha` 继续增大，召回率逐步下降，而多样性、覆盖率与新颖度的变化方向并不完全一致。这说明混合推荐不是简单地“权重越大越好”，而是存在明显的目标函数折中。

表 4: 混合权重扫描的关键结果

`alpha`	Recall	Diversity	Coverage	Novelty
0.0	0.0224	0.1361	0.2295	0.8519
0.2	**0.0450**	0.2261	0.3829	0.7973
0.4	0.0419	0.2891	0.3882	0.7922
0.6	0.0314	0.3404	0.4073	0.8121
0.8	0.0097	0.4217	0.4287	0.8528
1.0	0.0026	**0.7628**	**0.4572**	0.8276

5 可视化结果

5.1 方法级综合对比

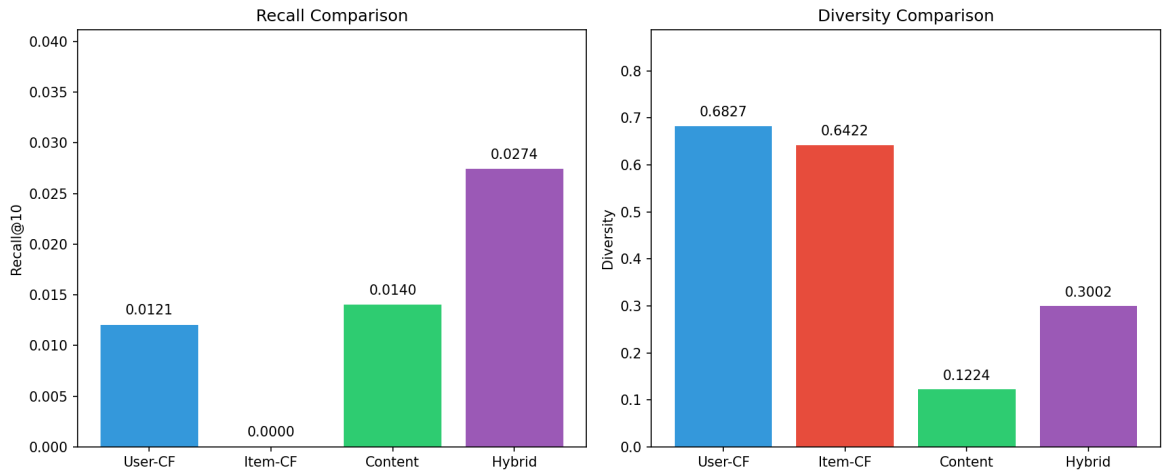

图 1: 四种推荐方法的综合指标对比

5.2 Recall@K 与权重变化

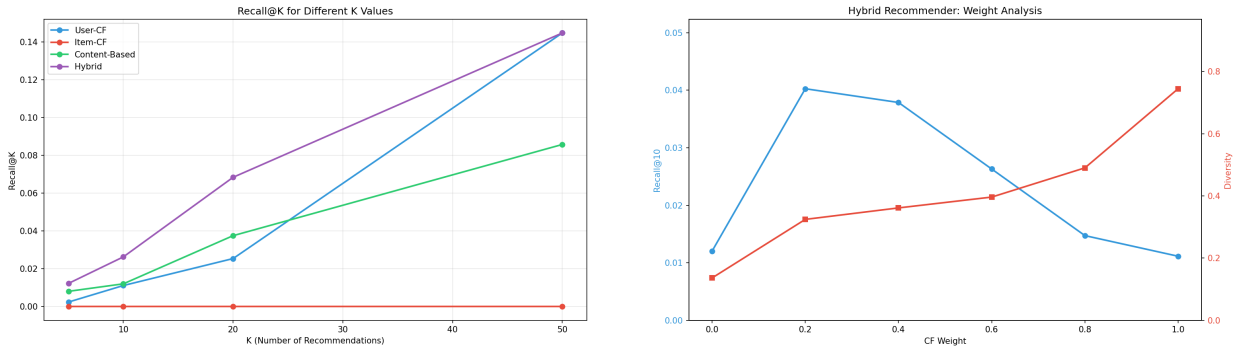

(a) 不同 K 下的 Recall@K 曲线

(b) 混合权重变化对指标的影响

图 2: 召回随 K 和 alpha 的变化

5.3 多目标权衡视图

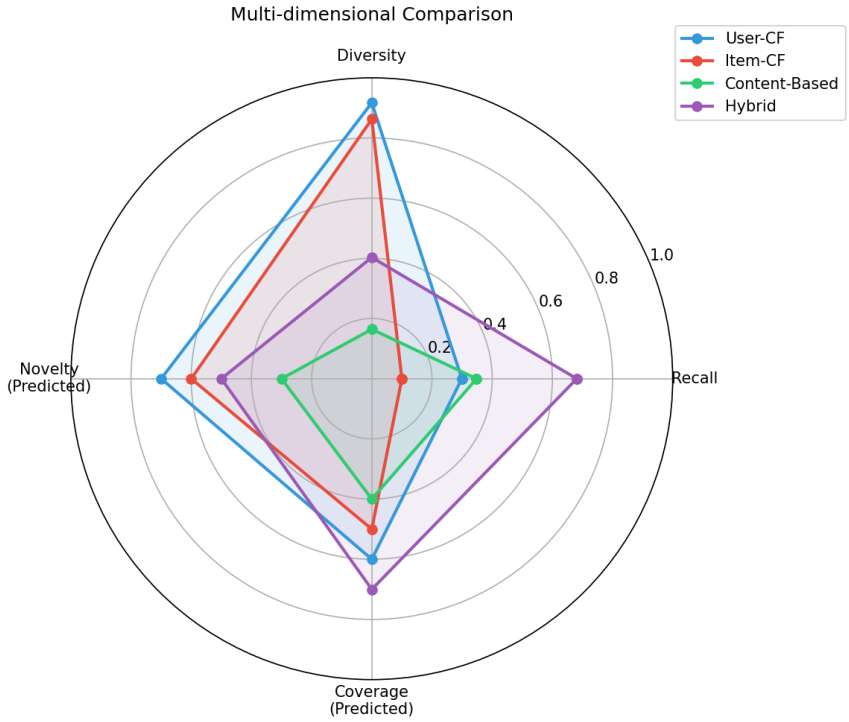

图 3: 四类方法在 Recall、Diversity、Coverage、Novelty 上的雷达图

6 分析

6.1 召回表现

Hybrid 在 `Recall@10` 上达到 0.0314，显著高于 Content-Based 的 0.0192、User-CF 的 0.0094 和 Item-CF 的 0.0002。更重要的是，它在 `Recall@5/10/20/50` 的全部区间里都保持领先，这说明该方法并非只是在某一个阈值上“碰巧更好”，而是在不同推荐列表长度下都具有更稳定的召回能力。

6.2 多样性、覆盖率与新颖度

User-CF 在多样性（0.7511）和覆盖率（0.5297）上最强，说明用户协同信号更容易扩展到不同电影集合；Item-CF 的新颖度最高（0.9966），意味着它更倾向于推荐低流行度物品；Content-Based 的多样性最低（0.1360），表明内容相似物品容易被反复推送。Hybrid 则落在中间位置，体现出推荐系统中典型的多目标折中。

6.3 权重结论

权重扫描是本次实验最有解释力的部分之一。结果显示，`alpha=0.2` 时召回率最好，说明内容信号在当前数据上对准确命中有帮助；而 `alpha=1.0` 时多样性和覆盖率明显更高，说明更强的协同过滤会提升推荐分散度，但召回却急剧下滑。当前提交版本采用的 `alpha=0.6` 并不是单指标最优，而是兼顾召回、稳定性和推荐面宽度的折中配置。

6.4 图表对应关系

- 图 1 给出四种方法的核心指标总览，便于快速判断方法级优劣；
- 图 2a 展示 Recall@K 曲线，验证 Hybrid 的优势在不同 `K` 下都成立；
- 图 2b 说明混合策略存在明显的权重敏感性；
- 图 3 将四个指标放到同一张图中，直观看出各方法的长短板。

7 结论

本实验完成了 MovieLens 100K 上四种推荐策略的实现、比较与可视化分析。真实结果表明，Hybrid 在召回率上表现最好，并且在不同 `K` 下都维持领先；User-CF 在多样性和覆盖率上更优，Item-CF 在新颖度上最强。权重扫描进一步说明，混合推荐的效果高度依赖 `alpha` 取值，当前提交版本采用的 `alpha=0.6` 体现的是多目标折中而非单一指标极值。整体上，本次实验给出的结论是明确的：若以召回优先，Hybrid 最有优势；若更看重推荐分散性和覆盖面，则 User-CF 或更高协同权重的配置更合适。

8 复现说明

在项目根目录执行以下命令即可复现数据结果与图表：

```
cd "/Users/lianglihang/Downloads/Principles-and-Techniques-of-Big-Data/\
作业7"
uv run --with numpy,pandas,scikit-learn,matplotlib \
  python src/hybrid_recommender.py
```

生成文件：

- `23336128-梁力航-作业 7.tex`
- `23336128-梁力航-作业 7.pdf`
- `results.json`

- figures/comparison.png
- figures/recall_at_k.png
- figures/weight_analysis.png
- figures/radar_chart.png